

$$Y_i = \beta_0 + \beta_1 \cdot X_i + \epsilon_i \quad \text{sent } \epsilon_i \sim N(0, \sigma)$$

$Y_i$ : valor de la variable resposta  $Y$  en el cas  $i$ -èsim

$X_i$ : valor que pren la condició  $X$  en el cas  $i$ -èsim

$\epsilon_i$ : error aleatori o distància a la recta del cas  $i$ -èsim

$\beta_0$  com a constant,  $\beta_1$  com a pendent;  $\sigma^2$  variància dels  $\epsilon_i$

### Exemple:

Homes adults i sans del Bcn:  $Y$  és pes en kg;  $X$  és alçada en cm. Suposem com a model una recta amb paràmetres:

$$\beta_0 = -100 \text{ kg} \quad \beta_1 = +1 \text{ kg/cm} \quad \sigma = 6 \text{ kg}$$

Quin pes correspon a un senyor de 160 cm?

$$Y = -100 + 1 \cdot 160 = 60 \text{ kg}$$

I un de 180 cm?

$$Y = -100 + 1 \cdot 180 = 80 \text{ kg}$$

Què significa "correspon"?

'Esperat, en mitjana'

Què significa  $\sigma = 6 \text{ kg}$ ?

Separar-se uns 6 kg del pes esperat és habitual. (Rarament és més del doble)

Què opines de l'etiqueta 'pes ideal' en algunes farmàcies?

Que ignoren la variabilitat natural.



## • Estimació dels paràmetres

$\beta_0$ ,  $\beta_1$  i  $\sigma^2$  són valors poblacionals, autèntics, desconeguts a 'estimar'. L'estimació dels dos primers, dona lloc a la recta estimada:

$$\hat{y}_i = b_0 + b_1 \cdot x_i$$

error de predicció i

$$e_i = y_i - \hat{y}_i$$

$$\hat{\beta}_1 = b_1 = \frac{S_{xy}}{S^2_x} = r \cdot \frac{S_y}{S_x}$$

$$\hat{\beta}_0 = b_0 = \bar{y} - b_1 \bar{x}$$

$$\hat{\sigma}^2 = s^2 = \frac{\sum (e_i^2)}{n-2} = \frac{(n-1) s_y^2 (1-r^2)}{n-2} = \frac{(n-1) (s_y^2 - b_1^2 S_x^2)}{n-2}$$

$S_{xy}$ : covariància mostral

$r = r_{xy}$  i correlació mostral



# Estimació dels paràmetres, Exemple

x	y
cervesa	alcohol
5	0.100
2	0.030
9	0.190
8	0.120
3	0.040
7	0.095
3	0.070
5	0.060
3	0.020
5	0.050
4	0.070
6	0.100
5	0.085
7	0.090
1	0.010
4	0.05

$$\bar{y} = \frac{\sum y_i}{n} = \frac{(0.1 + 0.03 + 0.19 + 0.12 + 0.04 + 0.095 + 0.07 + 0.06 + 0.02 + 0.05 + 0.07 + 0.1 + 0.085 + 0.09 + 0.01 + 0.05)}{16}$$

$$= 0.07375$$

$$\bar{x} = \frac{5+2+9+8+3+7+3+5+3+5+4+6+5+7+1+4}{16} = 4.8125$$

$$S_y^2 = \frac{\sum y_i^2 - \frac{(\sum y_i)^2}{n}}{n-1}$$

$$\sum y_i^2 = (0.1^2 + 0.03^2 + 0.19^2 + 0.12^2 + 0.04^2 + 0.095^2 + 0.07^2 + 0.06^2 + 0.02^2 + 0.05^2 + 0.07^2 + 0.1^2 + 0.085^2 + 0.09^2 + 0.01^2 + 0.05^2)$$

$$= 0.11625$$

$$\sum y_i = 1.18$$

$$S_y^2 = \frac{0.11625 - \frac{1.18^2}{16}}{16-1} = 0.001948$$

$$S_x^2 = 4.829167$$

$$S_{xy} = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{n-1}$$

$$S_{xy} = \frac{6.98 - \frac{77 \cdot 1.18}{16}}{16-1} = 0.08675$$

$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{0.08675}{\sqrt{4.829167} \cdot \sqrt{0.001948}} = 0.84441$$

Resultats de la regressió:

$$b_1 = \frac{S_{xy}}{S_x^2} = r_{xy} \cdot \frac{S_y}{S_x} = 0.01796$$

$$\bar{y} = -0.0127 + 0.01796 \cdot X_i$$

$$S \approx 0.077$$

$$b_0 = \bar{y} - b_1 \bar{x} = -0.0127$$

$$e_c = 0.100 - 0.077 = 0.023$$

$$S = \sqrt{\frac{\sum (e_i^2)}{n-2}} = 0.0204$$



## • Validació del model lineal. Anàlisi dels residus

$e_i$  vs "Fitted Values"  $\rightarrow$  Linealitat i homoscedasticitat

$e_i$  vs ordre observacions  $\rightarrow$  Independència

Qnorm dels residus ( $e_i$ )  $\rightarrow$  Premissa de Normalitat

Histograma dels residus ( $e_i$ )  $\rightarrow$  Premissa de Normalitat

### - $e_i$ versus Fitted values

- **Linealitat**: El núvol de punts ha de mantenir sempre la mateixa alçada

• que formen més o menys una línia recta

- **Homoscedasticitat**: La variabilitat dels residus ha de mantenir-se constant independentment dels valors predits.

• la distribució de los puntos tiene que ser igual, o todos juntitos o todos separados



## ei vs ordre de les observacions

- **Independència**: Els residus no han de mostrar cap patró enfront l'ordre
  - que no se alternen subides y bajadas y no haya ningún patrón

## qqnorm i histograma de residus

- **Normalitat**: Els residus han de ser normals: situarse sobre la recta en el qqnorm i forma de campana a l'histograma.

Generalment amb poques dades, és difícil avaluar les premisses: l'opció més prudent és acceptar-les a no ser que ho veiem clar que alguna d'elles s'infringeixi